

表情特徴量を用いたせん妄判別モデルに関する探索的研究

○仁保 貴耀¹、湯口 彰重¹、松本 吉央¹、大谷 清子²、小川 朝生²、岡留 有哉¹

1. 東京理科大学、2. 国立がん研究センター

せん妄とは

中枢神経の機能障害の一形態で、**入院者の約20%**にみられる短期的かつ突発的な認知症のような症状

- カテーテルや点滴の自己抜去や転倒による**ケガの原因**
- **認知症のリスク**が上昇
- **専門医が少なく適切な対応ができていない**
- 発症・重症化の予防が重要



せん妄は表情に変化が出ることが知られている

- 表情筋の変化が遅い
- 反応潜時が延長する



	せん妄	認知症
意識	意識障害がある	おおむね正常
発症時期	特定できる	特定できない
発症期間	数時間から数週間（一過性）	持続性
症状	突然暴れ出す 意味不明なことを口走る 妄想、幻覚、幻聴 攻撃的になる など	記憶障害 失見当識 [※] など

※時間、場所、人、状況などが正しく認識できなくなることを指す。

せん妄に関する関連研究

電子健康記録データ(カルテデータ)などを用いた予測研究

[Van den Boogaard et al., 2012]

- カルテデータなどを特徴量としてロジスティック回帰によるせん妄の予測の研究
 - ICU患者3056名の年齢、APACHE-IIスコアなどのカルテデータの特徴量
→曲線下面積(AUC):0.87
- 問題点
 - 特徴量の収集が困難
 - 患者が限定的(ICU,高齢患者など)
 - せん妄になり得る可能性の予測タスク
→リアルタイムでの判別が必要

せん妄に関する先行研究

表情データセットを用いた研究^[生田ら., 2023]

- 表情データセットを特徴量としてXGBoostによるせん妄の分類モデルの作成と分析に関する研究
 - 1～5分程度の患者の表情を特徴量として、XGBoostによる分類とSHAPによる特徴量の分析
- 5分割の交差検証による分類精度:91%
せん妄患者の瞼や眉、視線などの目元に特徴
- 問題点
 - 機械学習手法がXGBoost、特徴量設計は分散のそれぞれ1種類
 - 被験者数が少ない:21名
 - せん妄患者の判別が可能か定かではない(求めているものが異なる可能性)

研究目的

表情特徴量を用いた機械学習によるせん妄判別手法を開発する

- データセットの構築
 - 被験者数の増加
 - 撮影環境(手振れ、明るさ)を揃える工夫
- 最も高精度に判別できる手法の組み合わせの探索
 - 特徴量
 - 機械学習手法
 - パラメータチューニング

収録した表情データセット

国立がん研究センターの医療関係者と入院患者の会話場면을収録

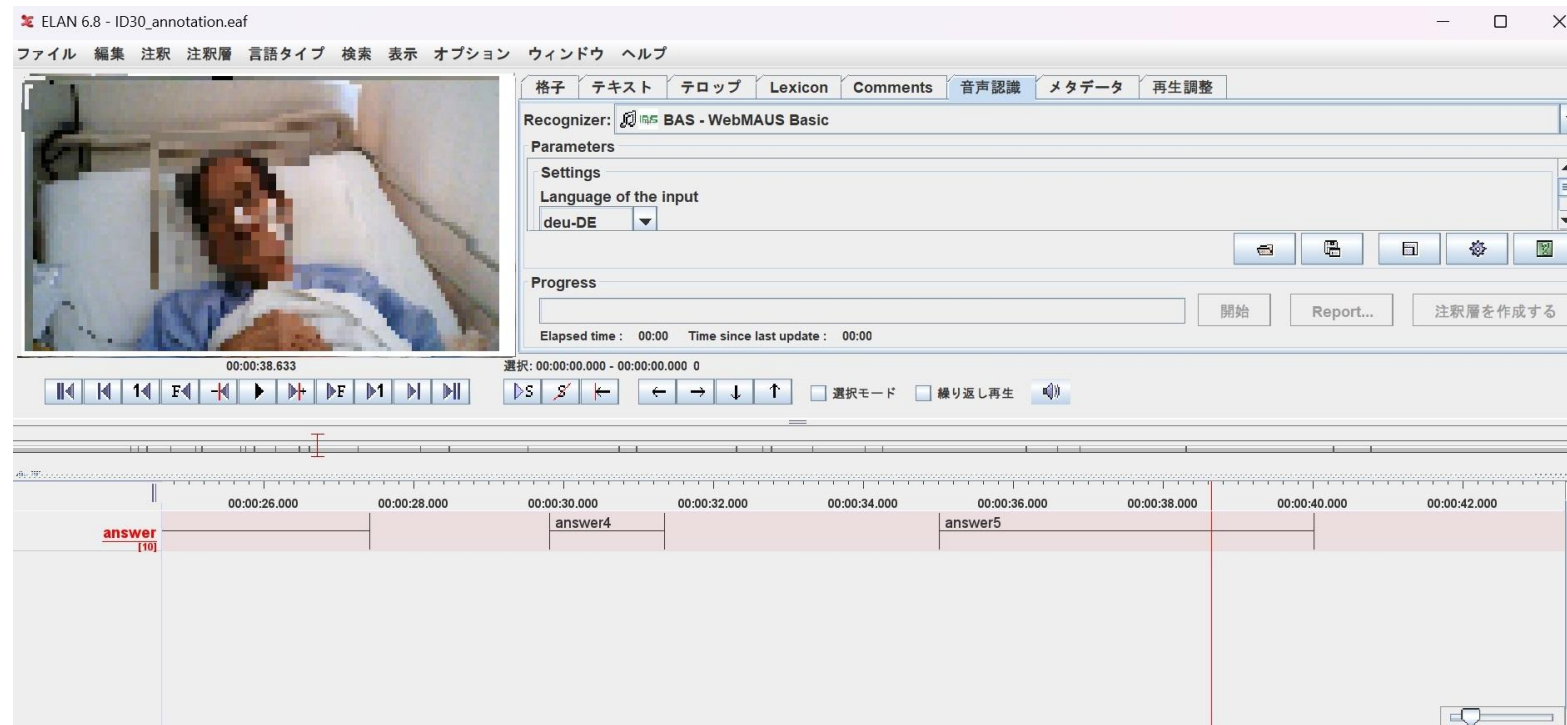
- 患者数：31名(せん妄患者：12名、非せん妄患者：19名)
- 動画長：3分程度
- 会話場面例：
 - 医療関係者→患者
「痛みはありますか？」
 - 患者→医療関係者
「今は痛みはありません。」



表情特徴量として使用する会話区間

医療関係者と患者の会話場面で使用する区間の検討

- 患者の発話区間の先頭10フレーム(0.3秒)もしくは30フレーム(1秒)を使用
 - 患者の発話区間が最小で約30フレーム
 - 発話区間をアノテーションツール(ELAN)^[1]を使用してラベル付け



[1]:<https://archive.mpi.nl/tla/elan/>

撮影環境の検証(理科大リビングラボ)

国立がん研究センターでの会話場面の環境で表情特徴が適切に取れているかの検証

- 明るさ17.5~520.7LUXの範囲、手持ち撮影での表情特徴の取得が可能なことを確認
 - 窓側、通路側の明るさの違いをおおむねカバー、手持ち撮影可能

明るい:520.7Lux



暗い:17.5Lux

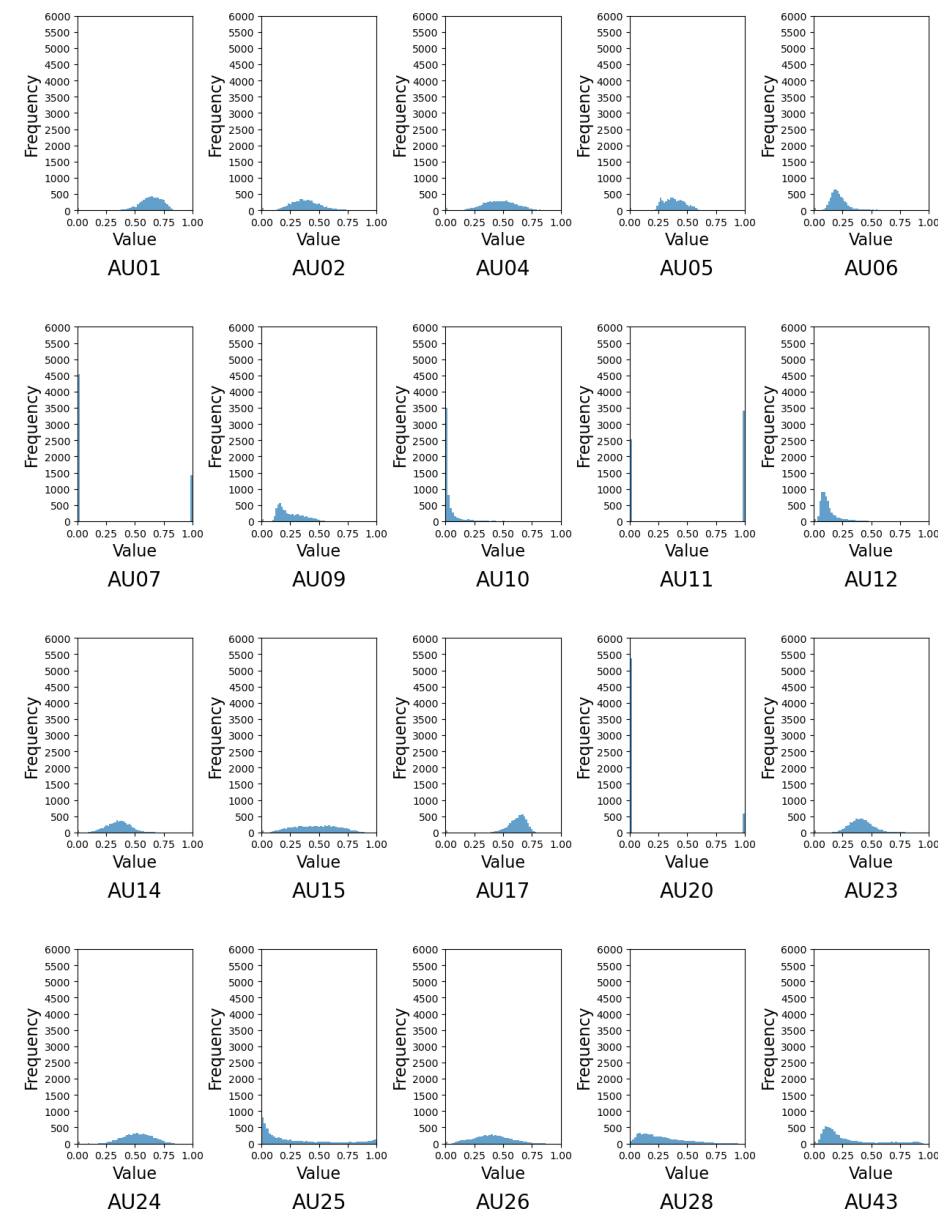



データセットから表情情報の抽出と特徴量設計

収録データに対してPyfeat^[Cheong et al., 2023]を用いて、Facial Action Unit(AU)を抽出

- 下図はPyfeatで取得可能な20種類のAUである
- 左図は患者一人に対して抽出したAUの分布を示している(縦軸:AUの値、横軸:値の出現回数)
- 実際にAU07, AU11, AU20は値が極端な二項分布である

→この3種類のAUを除いた17種類のAUを利用



データセットから表情情報の抽出と特徴量設計

使用する特徴量として以下の4種類を設計。それぞれ、患者の発話区間の先頭部分を利用し、算出する。 $(x_i : i$ 番目のフレームのAU値)

- 30フレームの平均値 $\mu_{30} = \frac{1}{30} \sum_{k=1}^{30} x_i$
- 10フレームの平均値 $\mu_{10} = \frac{1}{10} \sum_{k=1}^{10} x_i$
- 30フレームの標準偏差 $\sigma_{30} = \sqrt{\frac{1}{30} \sum_{k=1}^{30} (x_i - \mu_{30})^2}$
- 10フレームの標準偏差 $\sigma_{10} = \sqrt{\frac{1}{10} \sum_{k=1}^{10} (x_i - \mu_{10})^2}$

せん妄判別モデルの性能評価実験条件

使用する手法は以下の7種類:

- 回帰 → 線形回帰、ロジスティック回帰、SVM
- 木構造アルゴリズム → 決定木、ランダムフォレスト、XGBoost
- クラスタリング → k近傍法

機械学習手法

- ・線形回帰
- ・ロジスティック回帰
- ・SVM
- ・決定木
- ・ランダムフォレスト
- ・XGBoost
- ・k近傍法



特徴量設計

- ・ μ_{30} (30フレームの平均)
- ・ μ_{10} (10フレームの平均)
- ・ σ_{30} (30フレームの標準偏差)
- ・ σ_{10} (10フレームの標準偏差)

せん妄判別モデルの性能評価実験条件

最適なパラメータを設定するためにパラメータチューニング

- 学習データ30名分に対して3分割の交差検証でパラメータを決定

学習方法	パラメータ	設定値
ロジスティック回帰	正則度強度(C) ペナルティ(penalty) ソルバー(solver)	{0.01, 0.1, 1, 10, 100} L2 lgfgs
SVM	正則度強度 ガンマ カーネル	{0.1, 1, 10, 100} {1, 0.1, 0.01, 0.001} rbf
決定木	分割基準 深さ ノード分割の最小サンプル 葉ノードに必要な最小サンプル	{gini, entropy} {5, 10, 15} {2, 5, 10} {1, 2, 5}

せん妄判別モデルの性能評価実験条件

最適なパラメータを設定するためにパラメータチューニング

- 学習データ30名分に対して3分割の交差検証でパラメータを決定

学習方法	パラメータ	設定値
ランダムフォレスト	決定木の本数 木の最大深さ 分割の最小サンプル数 最大特徴量数	{100, 150} {10, 15, 20} {2, 5} sqrt
勾配ブースティング木 (XGBoost)	木の最大深さ 学習率 決定木の数 サブサンプル比率 特徴量のサンプリング比率	{3, 5, 7} {0.1, 0.01} {50, 100, 200} {0.8, 1.0} {0.8, 1.0}
k近傍法(kNN)	近傍数 重み 距離の種類	{3, 5, 7, 9} {uniform, distance} {euclidean, manhattan, minkowski}

せん妄判別モデルの性能評価実験

本実験では、せん妄の判別のために複数の機械学習手法と特徴量を使用してモデルを構築し、モデルの性能を比較する。

- モデルの学習方法: leave one person out法
 1. 入院患者31名分のデータの内、30名分を学習データとし、パラメータチューニングを行い、モデル構築
 2. 残り1名分をテストデータとして分類精度検証
 3. テストデータを変更して、1～2を繰り返す
→31名全員に対して行い、必ず1度はテストデータとして使用

せん妄判別モデルの性能評価実験の特徴量と評価項目

特徴量：

- 患者一人につき最大170個の特徴量を利用

評価項目：

- 感度：真に疾患を有する者を検査により陽性と正しく判定できた割合
- 特異度：真に疾患を有さない者を検査により陰性と正しく判定できた割合

例)機械学習手法：線形回帰、特徴量： μ_{30} のとき

分類結果/正解	分類：せん妄あり	分類：せん妄なし
正解：せん妄患者 (12人)	4人	8人
正解：非せん妄患者 (19人)	4人	15人



感度： $\frac{4}{12}$ (約33%)

特異度： $\frac{15}{19}$ (約79%)

結果

	特徴量							
	μ_{30}		μ_{10}		σ_{30}		σ_{10}	
	感度	特異度	感度	特異度	感度	特異度	感度	特異度
線形回帰	33	79	33	84	25	79	42	84
ロジスティック回帰	8	100	8	89	8	95	8	95
SVM	8	84	8	79	8	95	0	95
決定木	25	47	33	68	42	74	25	89
ランダムフォレスト	0	95	8	100	33	89	42	100
XGBoost	25	79	25	95	0	100	8	100
kNN	42	74	42	79	42	95	33	100

- 特異度が80%以上のものが多い
- どの組み合わせでも、感度は50%を超えない

感度、特異度がともに比較的精度が高い機械学習手法

	μ_{30}		μ_{10}		σ_{30}		σ_{10}	
	感度	特異度	感度	特異度	感度	特異度	感度	特異度
線形回帰	33	79	33	84	25	79	42	84
決定木	25	47	33	68	42	74	25	89
ランダムフォレスト	0	95	8	100	33	89	42	100
XGBoost	25	79	25	95	0	100	8	100
kNN	42	74	42	79	42	95	33	100

- 木構造のアルゴリズムよりもk近傍法で平均、標準偏差を特徴量としたときの感度が高い傾向
→ 木構造のアルゴリズムが今回使用したデータに適していない可能性
- 特徴量に平均よりも標準偏差を用いたときの特異度が全体的に高い傾向
→ 非せん妄患者のデータ変動を平均よりも反映しやすい
- k近傍法と比較した際に、ほぼすべての特徴量において線形回帰の感度が低い傾向
→ データが非線形に分布している

まとめ

- データセットの構築：
 - ・ 被験者数31名に増加
 - ・ 撮影環境の明るさや手振れによる影響なし、使用する区間のラベル付け
- 手法の組み合わせの探索：
 - ・ 4種類の特徴量
 - ・ 7種類の機械学習手法、パラメータの範囲設定
- 結果：
 - ・ k近傍法と標準偏差を特徴量としたときの感度がやや高い
→現状では、どの手法がせん妄の判別に最適か断定的なことはいえない
- 課題：
 - ・ 会話項目に沿わない場合の対処(声かけの統制)
 - ・ AUがどのくらい影響を与えている(特徴量の寄与の分析)



東京理科大学

付録


決定木の実験結果

	μ_{30}		μ_{10}		σ_{30}		σ_{10}	
	感度	特異度	感度	特異度	感度	特異度	感度	特異度
決定木	25	47	33	68	42	74	25	89

医療分野における機械学習技術を用いた診断支援

- 医療現場での機械学習を用いた診断支援
- 疾患の特徴が表情や音声に出やすい(パーキンソン病、うつ病など)
 - 患者の表情、音声データを使用して、診断の支援等をするシステムの開発
- 専門家が少ない地域、物理的に距離がある場所での診断支援

→ このような技術によってせん妄のような難しい疾患に対する診断補助手法の開発への期待



データセットから表情情報の抽出と特徴量設計

収録データに対してPyfeat^[Cheong et al., 2023]を用いて、Facial Action Unit(AU)を抽出

- 取得可能な20種類の内、値が安定しない3種類を除き、17種類のAUを利用
-AU07, 11, 20は値が二値であったため除く

